Analíse Estatística e Mineração de Sequências para Descobrimento de Táticas - Tênis

Orientador: Renato Vimieiro

Pedro Cimini Mattos de Freitas
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil
ciminipedro@gmail.com

***Abstract*—Nessa primeira parte do projeto, relatamos formas de caracterizar jogadores de tênis e suas táticas. Essas táticas podem ser entendidas como o estilo de jogo de cada jogador, suas preferências e tendências na quadra. Através da realização de uma análise estatística de dados agregados e da mineração de sequências de ações em jogos de tênis, somos capazes de encontrar essas tendências e explorá-las. Mostramos táticas de diferentes jogadores e encontramos padrões que se repetem entre eles. Com essas informações, é possível um maior entendimento sobre o tênis como um esporte, os elementos que o compõem e como eles interagem.**

I. Introdução

O uso e análise de dados no contexto esportivo, como no futebol [2] [4] e baseball [5], está revolucionando o cenário de cada um desses esportes. **Tênis**, sendo um dos esportes mais acompanhados e praticados ao redor do mundo, claramente se configura como um domínio interessante a ser explorado. Seus jogadores podem ser analisados por diversos ângulos. Podemos observar, por exemplo, como eles se comportam em diferentes tipos de superfície ou contra diferentes tipos de adversários. Como o tênis é um esporte individual, essas características demonstram, diretamente, o estilo de jogo de cada competidor. Naturalmente, nesse e em outros esportes, alguns jogadores se sobressaem de forma inquestionável. E compreender porque esses jogadores se sobressaem dessa forma é uma tarefa interessante. Devido ao número cada vez maior de dados que temos à disposição, torna-se útil a utilização de ferramentas e técnicas de ciência de dados para a realização dessas análises.

Nesta primeira parte do projeto, focamos primariamente em demonstrar como é possível caracterizar os jogadores de tênis e seus respectivos estilos. Será em grande parte uma exploração de diversos aspectos do jogo e dos jogadores que nos dará um maior entendimento da base de dados e tornará possível a realização de análises mais profundas na próxima parte do projeto. Para esse fim, escolhemos algumas facetas específicas para focar os nossos esforços. Elas são: **Serviço, Tipo e Direção dos Golpes e *Rallys***. Além disso, escolhemos focar as análises em cima de jogadores representativos e conhecidos. Por isso, escolhemos Roger Federer, Rafael Nadal, e Novak Djokovic, integrantes do que é chamado ***"Big 3"*** do tênis, jogadores amplamente considerados os melhores da história e que dividiram as quadras durante décadas. A opção por esses jogadores foi feita pois entendemos que os três são representativos de estilos diferentes de tênis, além de que uma análise feita em cima dos mesmos nos dá uma visão maior sobre as táticas utilizadas pelos jogadores de mais alto nível. Através dessas facetas e desses jogadores, conseguimos demonstrar a possibilidade da realização desse tipo de caracterização, que abre mais oportunidades para outras e mais profundas análises a serem realizadas na continuação desse projeto. Nas seguintes seções, iremos discutir trabalhos relacionados, a metodologia empregada ao longo desse projeto, nossa contribuição e os resultados e conclusões que foram tomadas.

II. Referencial Teórico

Trabalhos utilizando técnicas de mineração de dados, no contexto de esportes, com diferentes finalidades [6], já é relativamente comum e vem crescendo ao longo do tempo. Especificamente relacionados aos objetivos deste projeto, podemos citar um artigo de rugby [1], onde através de técnicas supervisionadas de mineração de padrões sequenciais, os pesquisadores são capazes de encontrar sequências de ações capazes de determinar se uma jogada terminará com o time pontuando ou não.

Ainda mais próximo ao nosso projeto, podemos citar um artigo sobre tênis de mesa [3], que busca encontrar e visualizar táticas no tênis de mesa utilizando-se de técnicas de descoberta de subgrupos. Entendemos que aplicar técnicas semelhantes ao tênis seria um próximo passo natural e interessante.

III. Metodologia

O objetivo dessa primeira parte do projeto é encontrar maneiras bem sucedidas de caracterizar jogadores. Para realizar essa caracterização, precisamos de alguma forma entender as disputas que ocorrem durante um jogo de tênis. Isso é, precisamos entender as ações tomadas pelos jogadores. Podemos olhar para as informações de duas formas diferentes: primeiramente, podemos pegar os dados agregados das partidas disputadas pelos jogadores que queremos caracterizar. Dessa forma, teremos acesso a informações sobre as ações tomadas por esse jogador durante o jogo e o resultado

destas mesmas ações. Sem dúvidas, isso é uma informação valiosa. Porém, tomando os dados dessa forma, perdemos uma informação sobre como os pontos foram disputados, nos restando apenas os dados em seu estado final. Portanto, devemos também nos utilizar das informações ponto a ponto, que nos dão informações sobre como cada ponto individual foi disputado. Dessa forma, temos acesso a sequência de ações que foram tomadas pelos jogadores e podemos realizar análises em cima dessas sequências.

Portanto, com esses dados à nossa disposição, realizamos análises estatísticas com os dados agregados para que possamos encontrar informações sobre os jogos disputados pelos jogadores que estão sendo focados. Assim, podemos descobrir como os pontos foram finalizados durante o jogo (**Winners, Erros Forçados, Aces, ...**), podemos descobrir a quantidade e o tipo e direção dos golpes utilizados pelos jogadores e podemos analisar como eles respondem à diferentes situações como, por exemplo, rallys mais curtos ou mais longos. Além disso, utilizando os dados ponto-a-ponto, podemos realizar uma mineração de sequências frequentes para esses pontos, o que nos retorna informação sobre como os pontos são disputados e quais subsequências de ações acontecem com mais frequência. Esses conceitos são mais explorados nas subseções abaixo.

A. Dataset

Os dados que serão utilizados provém do **Tennis Abstract Match Charting Project (TAMCP)**, um projeto coletivo que coleta dados detalhados rebatida por rebatida de jogos profissionais de tênis. Ele possui dados de **14,416 jogos**, **2,250,373 pontos** e **8,617,097 rebatidas**.

B. Análise Estatística

Realizamos a análise estatística em cima dos dados de cada jogo que temos à disposição. Esses dados são compostos de informações sobre os seguintes aspectos do jogo

- **Serviços -** Informações sobre o resultado de um serviço, sendo subdivididos pela direção do mesmo.
- **Golpes -** A frequência e o resultado de cada tipo de golpe utilizado por cada jogador em um determinado jogo.
- **Rallys -** Os resultados dos pontos de cada jogador em um determinado jogo, divididos pela duração dos rally.
- **Pontos Chave -** Pontos Chave são aqueles que têm significado especial dentro de uma partida. Em contraste a pontos normais, eles têm uma maior importância e uma boa performance durante esses pontos é chave para a vitória.

Utilizando esses diferentes domínios, podemos começar a formar uma imagem de um determinado jogador. A forma como ele joga será representada pelo volume produzido por ele em cada um dos quesitos. Para dar um exemplo simples, existem jogadores que podem ter tendências a sacar mais aberto ou mais fechado. Ou, então, jogadores que tendem a vencer os pontos com rallys menores e perderem com maior frequência os maiores. Esse tipo de informação, portanto, carrega o estilo do jogador destacado e permite que façamos afirmações sobre seu jogo. Permite, também, a diferenciação entre dois jogadores distintos.

C. Mineração de Sequência de Rallys

Temos acesso a sequência de ações tomadas por cada jogador, ou *rally*, ponto a ponto. Dessa forma, podemos realizar uma mineração de sequências frequentes em cima desses *rallys*. Ao realizarmos essa mineração, obtemos as subsequências que se repetem com maior frequência durante os pontos que estamos utilizando como entrada. Isso nos dá informação sobre como o ponto se desenvolve, além de nos dar informações sobre que sequências um jogador tem uma maior tendência de utilizar.

Podemos ir um passo adiante, e realizar essa mineração apenas para sequências que compõe os golpes finais que diretamente levam a finalização de um ponto. Em outras palavras, isso nos dará informação sobre a tática que um jogador costuma empregar para finalizar pontos.

IV. Contribuições

Nesta seção, iremos discutir e exemplificar os resultados que encontramos durante o projeto. Os dados utilizados serão dos jogadores Roger Federer, Rafael Nadal e Novak Djokovic. Iremos olhar para o período entre os anos de 2005 e 2020, anos nos quais os 3 dividiram as quadras e obtiveram grande sucesso esportivo. Antes de observarmos os resultados, no entanto, faz-se necessário a explicitação de algumas definições.

A. Definições

Para que os resultados fiquem claros, é necessário uma familiaridade com certos termos e conceitos do mundo do tênis. Para facilitar, portanto, a leitura desse documento, faremos a definição dos termos mais importantes e possivelmente desconhecidos do público geral acerca do tênis e que serão frequentemente utilizados durante a demonstração dos resultados. Esses termos são referentes às pontuações principais de um jogo de tênis.

- **Rally -** O rally é o nome dado a troca de golpes realizadas pelos jogadores. Basicamente, pode ser entendido como a sequência de ações tomadas durante um determinado ponto.
- **Ace -** Pontuação realizada diretamente por um serviço, que não é retornado pelo outro jogador.
- **Winner -** Pontuação onde um jogador consegue atravessar a bola para o lado adversário sem que o jogador adversário consiga rebater/encostar na bola.
- **Forced Error -** Pontuação na qual, através de um golpe que dificulta a rebatida do adversário, um jogador induz o adversário ao erro.
- **Unforced Error** - Pontuação na qual um jogador, sem nenhuma influência de seu adversário, comete um erro no momento de tentar atravessar a bola para o lado do adversário.

A estrutura de um jogo de tênis segue o formato : ***Game - Set - Match***. Quem ganha 6 ***Games***, ganha 1 ***Set***. Ganhar 2 ou 3 *Sets* (dependendo do nível da competição), ganha o ***Match***

(jogo). Com essas definições básicas explicitadas, podemos analisar os dados.

B. Geral

Antes de aprofundarmos em qualquer aspecto mais específico, vamos olhar algumas características mais gerais como na Tabela I

TABLE I
ESTATÍSTICAS GERAIS

	Pontos - Serviço	Pontos - Recepção	% Pts - Serviço	% Pts - Recepção
Federer	50459	53917	0.483	0.517
Nadal	31937	33238	0.49	0.51
Djokovic	39505	40977	0.491	0.509

Inicialmente, podemos ver que todos os 3 jogadores disputam mais pontos de recepção (0.51%) do que de serviço (0.49%). A diferença é mínima, porém já é uma característica que traz informação. Essa diferença mostra que, possivelmente, jogadores da qualidade de Federer, Nadal e Djokovic são capazes de acabar os seus *games* de serviço de forma mais rápida. Pela mesma razão, eles são capazes de estender os *games* de serviço de seus adversários e, dessa forma, disputam mais pontos nessa condição. A figura 1 mostra algumas informações adicionais sobre esses pontos

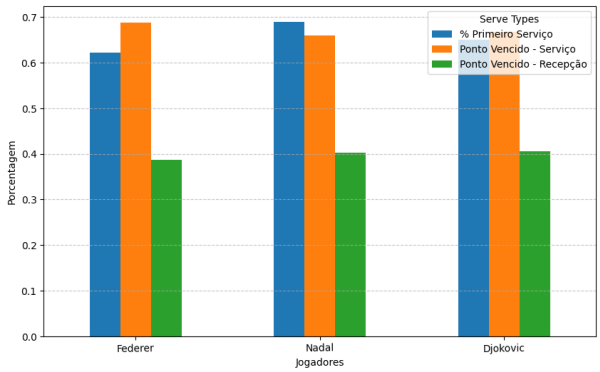

Fig. 1. Estatísticas Gerais

A taxa de primeiro serviço para os 3 é maior do que 60%, com Nadal tendo a melhor marca nesse quesito. Para cada ponto disputado com o serviço, os 3 também ficam próximos de 60% dos pontos ganhos, com Federer tendo a maior taxa. Isso contrasta com os pontos em que eles estão na recepção, onde todos tem 40% dos pontos vencidos, com Djokovic sendo o melhor, por pouco. Isso destaca, também, a grande importância do serviço para a vitória de pontos. Da mesma forma, mostra a dificuldade, até para os melhores jogadores, de ganhar pontos na recepção.

Podemos ver, já nessa seção inicial, como mesmo informações básicas sobre o jogo já nos remetem a alguns aprendizados sobre as características de cada jogador. É interessante manter essa informação em mente enquanto aprofundamos sobre as estatísticas de alguns fundamentos e aspectos do jogo nas próximas seções.

C. Serviços

O serviço é um fundamento importante do tênis. Se bem executado, o jogador pode tomar controle do ponto disputado. As tabelas a seguir demonstram esse fator de controle, ao mostrar qual o resultado dos pontos baseados no fato de se foi primeiro ou segundo serviço. No tênis, um jogador tem duas chances de realizar seu serviço. Caso acerte de primeira, o ponto jogo é um ponto de primeiro serviço e, caso contrário, é um ponto de segundo serviço. Se o jogador errar nas suas duas oportunidades de serviço, o ponto é dado ao adversário e damos a essa pontuação o nome de ***Double Fault*** (Dupla Falta).

TABLE II
PRIMEIRO SERVIÇO - ESTATÍSTICAS

	Serviço	Aberto	No Corpo	Na linha do T	Vencido	Aces
Federer	25419	12765	2126	10528	0.77	0.15
Nadal	19233	7946	4146	7141	0.71	0.06
Djokovic	18733	8786	2336	7611	0.72	0.09

TABLE III
SEGUNDO SERVIÇO - RESULTADOS

	Serviço	Aberto	No Corpo	Na linha do T	Vencido	Aces
Federer	14957	5965	4389	4603	0.56	0.01
Nadal	8536	2468	3604	2464	0.56	0.0
Djokovic	9958	3839	3348	2771	0.55	0.01

Como pode ser visto, a porcentagem de pontos vencidos do primeiro serviço é bem maior do que a do segundo serviço. Igualmente, a taxa de *Aces* diminui a ponto de virtualmente zerar para todos os jogadores. O perigo de cometer uma dupla falta é, portanto, demonstrado por essas tabelas. O jogador se torna mais cauteloso no seu segundo serviço. Essa cautela previne a dupla falta, porém é claramente demonstrado que isso tem um grande impacto no tamanho da influência do serviço no ponto. Pontos de segundo serviço são um desafio maior para o sacador do que pontos de primeiro serviço. Além disso, podemos perceber também que Federer tem a maior taxa de *Aces* entre os 3, mostrando portanto sua proficiência nesse fundamento.

Podemos considerar, também, o tipo de serviço realizado. Temos o *Wide* (Aberto), *Body* (No corpo) e *Down the T* (Na linha do T). As tabelas IV,V,VI mostram as estatísticas para cada uma dessas situações:

TABLE IV
SERVIÇOS - FEDERER

	Total De Pontos	Winner	Forced Error	Unforced Error
Wide	13246	0.398	0.434	0.168
No Corpo	3816	0.269	0.372	0.359
DownTheT	10895	0.442	0.402	0.156

TABLE V
SERVIÇOS - NADAL

	Total De Pontos	Winner	Forced Error	Unforced Error
Wide	7172	0.325	0.432	0.242
No Corpo	4744	0.226	0.379	0.395
DownTheT	6464	0.307	0.411	0.281

TABLE VI
SERVIÇOS - DJOKOVIC

	Total De Pontos	Winner	Forced Error	Unforced Error
Wide	8475	0.331	0.457	0.212
No Corpo	3326	0.225	0.377	0.398
DownTheT	7110	0.345	0.43	0.224

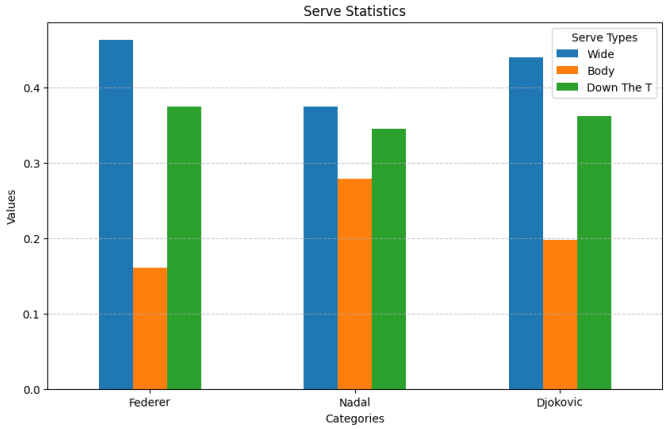

Fig. 2. Porcentagem de Serviços por Jogador e Tipo

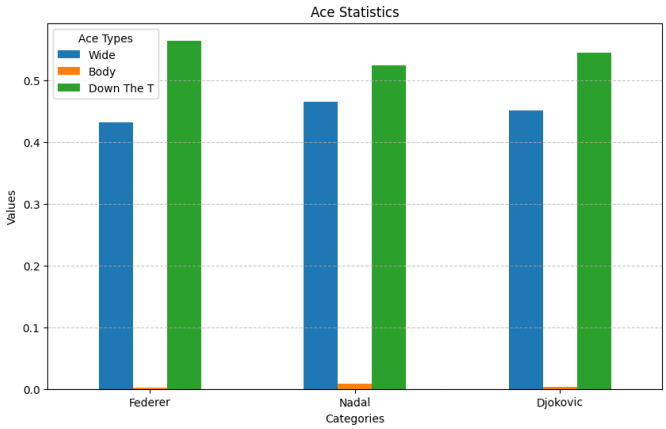

Fig. 3. Porcentagem de Aces por Jogador e Tipo

Pelas tabelas, percebemos que todos 3 tem a preferência por um serviço aberto. No entanto, Nadal se diferencia pelo fato de que utiliza do serviço no corpo mais vezes do que seus rivais, chegando a 25% do seu total.

No entanto, se olharmos para as figuras 2 e 3, podemos ver duas coisas interessantes. A 2 visualiza as taxas de serviço de cada tipo para cada um dos jogadores, enquanto a 3 faz o mesmo, só que apenas para *aces*. Ao olharmos para essas figuras podemos ver claramente duas disparidades. Primeiramente, a taxa de serviços no corpo (***Body***) supera 15% para todos os 3 e, mesmo assim, o número correspondente de aces tende a 0%. Dessa forma, o saque no corpo parece ser uma medida de segurança dos jogadores. Como são menos arriscados, acontecem menos *aces*. Esse fator "segurança" é também corroborado pelo número elevado desse tipo de saque durante o segundo serviço, como podemos ver na tabela III.

Além disso, no caso dos saques "Na Linha do T" (Down The T) podemos ver uma situação oposta ocorrendo. Eles são menos utilizados do que os saques "Abertos" no geral, porém, olhando apenas para os *Aces*, eles se tornam os mais representativos para todos os 3, como podemos ver na figura 3. Dessa forma, devido a utilização desse saque e o seu aparente sucesso em situações de *Ace*, é possível considerar esse fator como uma tática desses jogadores de elite: saques majoritariamente abertos, porém utilizando-se de saques na linha do T para pegar os adversários desprevinidos e pontuar com um *Ace*.

Além do tipo de serviço, podemos olhar também para situações específicas que ocorrem logo em seguida. Situações de **"Saque e Voleio"** (SeV), como são chamadas, denominam a ação de realizar o seu serviço e imediatamente se aproximar da rede. A tabela VII tem os dados sobre essa ação.

Podemos ver um jogador se destacar de forma clara. Federer tem mais de 10 vezes o número de jogadas de **SeV** do que Nadal e quase 10 vezes mais do que Djokovic. Mesmo com esse número mais elevado, ele consegue manter uma taxa de 70% de vitórias nesse tipo de ponto, um pouco mais alta do que os 65% de Djokovic e um pouco abaixo dos 80% de Nadal. De qualquer forma, isso pode ser considerado uma tática de Federer que não é compartilhada em escala comparável por seus rivais.

TABLE VII
SAQUE E VOLEIOS - RESULTADOS

	Total	Vencidos	Winner	Forced Error	Unforced Error
Federer	2962	2064	0.494	0.433	0.073
Nadal	262	212	0.566	0.41	0.024
Djokovic	329	214	0.467	0.463	0.07

Outro fator das jogadas de **SeV** que pode ser percebido é a taxa baixíssima de pontos vencidos por **Erros Não Forçados**. Uma explicação para isso, é que a tática de **SeV** é extremamente agressiva, o que torna a finalização em ***Winners*** e **Erros Forçados** bem mais comum.

D. Golpes

Outro aspecto do jogo que podemos observar são os golpes utilizados por cada jogador durante suas partidas. Dessa forma, poderemos ter uma ideia de quais são seus favoritos e qual o resultado decorre da utilização de cada um deles. Existem diversos golpes no tênis, porém focaremos em alguns que são mais comumente utilizados. Sendo assim, focaremos em:

- ***Forehand*** **-** Golpe executado com a mão dominante voltada para a direção do golpe.
- ***Backhand*** **-** Golpe executado com as costas da mão dominante voltadas para a direção do golpe.
- ***Slice*** **-** Golpe executado quando o jogador ”corta” a bola, adicionando rotações para trás na bola, afetando a sua velocidade, tirando o peso da bola e tornando imprevisível sua trajetória após o contato com a quadra.

Além disso, vamos explicitar as definições das siglas utilizadas nas tabelas, para facilitar o entendimento das mesmas:

- **XC -** ***Crosscourt*****:** Golpe **cruzado**. O jogador atravessa a bola de um lado da quadra para o outro
- **DTM-** ***Down The Middle*****:** Golpe direcionado ao **meio** da quadra
- **DTL -** ***Down The Line*****:** Golpe onde a bola segue paralela a direção das linhas laterais da quadra. Por essa razão, em portugûes, é chamada de **”Paralela”.**
- **IO -** ***Inside-out*****:** Depende do golpe. Em um *Forehand - IO*, o jogador realiza um *forehand* do seu lado **não-dominante** e abre a bola para o lado oposto da quadra. Um *Backahnd - IO* acontece quando o jogador realiza um *backhand* do lado do **dominante** e também abre a bola para o lado oposto.
- **II -** ***Inside-in*****:** O mesmo conceito do *Inside-out*, porém com a diferença de que a bola é retornada na paralela.

1) Forehand: As tabelas VIII - X são referentes às estatísticas de *forehand* para cada um dos 3 jogadores de interesse. Para todos os jogadores, esse golpe possui uma alta taxa de *winner* e relativamente alta de erros forçados. Essa taxa é mais alta, na média, do que os demais golpes que veremos a seguir. Além disso, é possível notar que tem, também, uma alta taxa de finalização para todas as variações do golpe. Para todos os 3, o golpe paralelo tem as maiores taxas de finalização, junto com os *forehands - II* para Federer e Nadal e *forehands - IO* para Djokovic.

Ao compararmos o número de *forehands* **DTM** e **DTL**, pode-se perceber duas informações interessantes: O volume de **DTMs** é maior, porém a taxa de finalização dos golpes **DTL** é muito maior. Dessas informações, é possível retirar uma estratégia/tática que está sendo empregada pelos 3. Os golpes no meio são utilizados mais vezes, pois são golpes mais simples de se realizar e, no momento certo, um ataque na paralela é utilizado para finalizar o ponto. Para Nadal e Federer isso fica ainda mais claro, pois os golpes ***Inside-In*** também são na paralela. Os golpes **DTM**, também, apresentam uma taxa desproporcionalmente elevada de erros não forçados, o que destaca o quão ”seguro” o golpe é. Os jogadores só pontuam nessa situação quando há um erro próprio do adversário.

2) Backhand: As tabelas **XI - XIII** são referentes às estatísticas de *backhands*. Se nos atentarmos à taxa de erros não forçados, veremos que ela é, em média, mais elevada do que a dos *forehands* para todos os jogadores. Como o *backhand* é, por definição, um golpe do lado não-dominante de um jogador, isso é explicado por essa maior dificuldade de finalizar pontos, que pode ser também vista pela menor taxa de finalização presente para a maioria das variações do golpe se comparadas às mesmas de um *forehand*. Porém é interessante perceber que, também nesse caso, as bolas **DTL** são as com maiores taxas de finalização e de *winners*, enfatizando o uso do golpe na paralela para a finalização de pontos, enquanto os demais golpes são usados na construção do mesmo. Para Nadal, a maior taxa de *winner* é do golpe **Inside-In**, porém isso pode ser explicado pelo baixo volume do mesmo. **B-DTL** continua sendo a maior taxa para golpes com volumes significativos.

TABLE VIII
FOREHAND - FEDERER

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
F-XC	17963	0.311	0.326	0.294	0.38
F-DTM	10602	0.118	0.098	0.172	0.73
F-DTL	5412	0.373	0.382	0.229	0.388
F-IO	12045	0.349	0.402	0.258	0.34
F-II	3048	0.405	0.354	0.314	0.331

TABLE IX
FOREHAND - NADAL

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
F-XC	18212	0.208	0.337	0.342	0.321
F-DTM	8943	0.072	0.051	0.151	0.798
F-DTL	5960	0.27	0.309	0.237	0.454
F-IO	10829	0.263	0.332	0.291	0.377
F-II	1504	0.389	0.342	0.385	0.274

TABLE X
FOREHAND - DJOKOVIC

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
F-XC	23975	0.138	0.308	0.36	0.331
F-DTM	7844	0.071	0.079	0.159	0.762
F-DTL	5633	0.403	0.461	0.24	0.299
F-IO	10049	0.326	0.43	0.282	0.288
F-II	3040	0.25	0.313	0.378	0.309

TABLE XI
BACKHAND - FEDERER

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
B-XC	13830	0.202	0.22	0.221	0.558
B-DTM	10597	0.113	0.045	0.142	0.81
B-DTL	5007	0.441	0.351	0.192	0.457
B-IO	982	0.385	0.347	0.132	0.521
B-II	28	0.429	0.25	0.333	0.417

TABLE XII
BACKHAND - NADAL

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
B-XC	19019	0.13	0.22	0.282	0.498
B-DTM	11122	0.074	0.029	0.19	0.781
B-DTL	6609	0.329	0.269	0.247	0.483
B-IO	2694	0.255	0.213	0.252	0.536
B-II	61	0.164	0.3	0.2	0.5

TABLE XIII
BACKHAND - DJOKOVIC

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
B-XC	12824	0.19	0.25	0.295	0.454
B-DTM	8477	0.064	0.042	0.177	0.779
B-DTL	5758	0.217	0.316	0.232	0.45
B-IO	1598	0.183	0.26	0.295	0.445
B-II	224	0.174	0.308	0.154	0.538

3) Slice: Por último, o golpe que será discutido é o *slice*. Deve-se ressaltar que *slices* podem ser tanto *forehands* (dominantes) como *backhands* (não-dominantes), porém essa informação não está disponível no conjunto de dados e não foi possível construí-la a partir das informações base. Sendo assim, tomaremos o *slice* como um todo, relembrando suas características previamente definidas.

Pelas tabelas XIV - XVI, podemos perceber que o volume desse golpe é mais reduzido do que o dos demais. Podemos perceber, também, que a taxa de finalização é igualmente reduzida para todos os 3 jogadores. Dessa forma, podemos afirmar que sua utilização não acontece com a intenção de pontuar. Isso significa que o slice tem outra função, de característica mais auxiliar. É utilizado para a construção do ponto, para "ganhar tempo" em cima do adversário, mas, geralmente, não é utilizado para finalizar o ponto. Por último, se compararmos o volume de uso desse golpe entre os 3, podemos perceber que Federer o utiliza com maior frequência que seus rivais, indicando que o *slice* é uma parte mais importante do jogo dele.

TABLE XIV
SLICES - FEDERER

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
S-XC	6628	0.071	0.064	0.262	0.672
S-DTM	3169	0.063	0.065	0.111	0.819
S-DTL	1737	0.16	0.198	0.288	0.514
S-IO	255	0.102	0.115	0.308	0.577
S-II	19	0.158	0.333	0.333	0.333

TABLE XV
SLICES - NADAL

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
S-XC	2508	0.077	0.135	0.177	0.688
S-DTM	1520	0.039	0.034	0.186	0.78
S-DTL	634	0.159	0.119	0.317	0.564
S-IO	175	0.16	0.0	0.286	0.714
S-II	8	0.25	0.0	0.0	1.0

E. Rallys

1) Estatísticas Agregadas: Através da análise estatística e a utilização de técnicas de mineração de sequências, somos capazes de encontrar informações relevantes sobre o estilo de jogo de jogadores de tênis. Essas informações podem ser úteis para treinadores e para os próprios jogadores no momento de analisar seu próprio jogo e encontrar suas forças e fraquezas, seus hábitos e vícios como jogador.

TABLE XVI
SLICES - DJOKOVIC

	Shots	Finalizador	Winner	Erro Forçado	Erro Não Forçado
S-XC	1344	0.092	0.258	0.379	0.363
S-DTM	2574	0.035	0.056	0.244	0.711
S-DTL	2059	0.068	0.129	0.266	0.604
S-IO	430	0.072	0.065	0.29	0.645
S-II	33	0.061	0.5	0.0	0.5

TABLE XVII
PORCENTAGEM POR TAMANHO DE RALLY - FEDERER SERVIÇO

	Vencidos	Perdidos	Winner	Forced Error	Unforced Error
Totality	27954	12417	0.397	0.413	0.189
1-3	20707	5057	0.369	0.472	0.159
4-6	3632	4950	0.517	0.247	0.236
7-9	2446	993	0.46	0.234	0.305
10-	1169	1417	0.397	0.257	0.346

Pela Tabela XVII, podemos perceber algumas tendências. Com o aumento do tamanho do *rally*, podemos ver que o número de **Erros Não Forçados** aumentam gradativamente. Isso vem acompanhado de uma diminuição tanto em ***Winner*** quanto em **Erros Forçados**. Uma interpretação para isso seria que, com a maior duração dos pontos, o desgaste físico dos jogadores aumenta, levando a uma maior quantidade de erros não forçados, e diminuindo as outras pontuações em igual medida. Podemos perceber, também, como a importância do serviço é evidente: Pontos que acabam em **"1-3"** golpes, tem a taxa de vitória muito elevada, que diminui com o aumento do número de golpes.

TABLE XVIII
PORCENTAGEM POR TAMANHO DE RALLY - DJOKOVIC SERVIÇO

	Vencidos	Perdidos	Winner	Forced Error	Unforced Error
Totality	18820	9724	0.318	0.433	0.249
1-3	11887	3291	0.295	0.529	0.176
4-6	2712	3631	0.372	0.283	0.345
7-9	2512	978	0.358	0.26	0.381
10-	1709	1824	0.328	0.263	0.409

TABLE XIX
PORCENTAGEM POR TAMANHO DE RALLY - NADAL SERVIÇO

	Vencidos	Perdidos	Winner	Forced Error	Unforced Error
Totality	18335	9372	0.293	0.411	0.296
1-3	10978	2879	0.246	0.526	0.227
4-6	2727	3447	0.373	0.235	0.392
7-9	2769	1079	0.351	0.229	0.419
10-	1861	1967	0.365	0.26	0.374

Como podemos ver nas tabelas XVIII e XIX, essas mesmas tendências podem ser encontradas para Nadal e Djokovic. É interessante perceber como para *rallys* de tamanho entre 4-6, uma inversão de pontos vencidos e perdidos é observada.

Necessariamente, como o serviço pode ser considerado o primeiro(1) golpe, se um ponto for finalizado no golpe 4 ou 6, isso significa que ele se encerra com uma ação do adversário, o que, em parte, explica essa inversão.

Como vamos ver nas próximas tabelas, o mesmo tipo de inversão acontece para os rallys onde Federer, Nadal e Djokovic estão recebendo o serviço.

TABLE XX
PORCENTAGEM POR TAMANHO DO RALLY - FEDERER RECEPÇÃO

	Pontos Vencidos	Pontos Perdidos	Winner	Forced Error	Unforced Error
Totality	16711	26612	0.273	0.225	0.418
1-3	6143	18289	0.095	0.181	0.499
4-6	6826	3790	0.36	0.255	0.384
7-9	1527	2984	0.396	0.251	0.351
10-	2215	1549	0.412	0.24	0.347

TABLE XXI
PORCENTAGEM POR TAMANHO DO RALLY - NADAL RECEPÇÃO

	Pontos Vencidos	Pontos Perdidos	Winner	Forced Error	Unforced Error
Totality	11715	17358	0.243	0.202	0.478
1-3	4147	11516	0.069	0.133	0.583
4-6	4466	2470	0.322	0.231	0.447
7-9	1136	2118	0.357	0.238	0.403
10-	1966	1254	0.366	0.261	0.373

TABLE XXII
PORCENTAGEM POR TAMANHO DO RALLY - DJOKOVIC RECEPÇÃO

	Pontos Vencidos	Pontos Perdidos	Winner	Forced Error	Unforced Error
Totality	11810	17423	0.218	0.242	0.461
1-3	4046	11284	0.1	0.216	0.455
4-6	4185	2268	0.265	0.245	0.49
7-9	1176	2190	0.304	0.249	0.447
10-	2403	1681	0.296	0.277	0.426

Observando as Tabelas XX,XXI,XXII, que mostram as mesmas estatísticas anteriores, mas para os casos onde os três estavam recebendo, ao invés de sacando, temos uma tendência muito clara. A maior parte dos pontos dos jogadores vem de **Erros Não Forçados**, o que novamente demonstra a importância do serviço no controle de um ponto. Estando na recepção, a maior chance de pontuação, inclusive para jogadores de alto nível, vem de um erro adversário. No entanto, temos também uma inversão da situação passada: com o aumento do tamanho dos *rallys*, temos também um aumento na proporção de pontos vencidos, enfatizando novamente como a influência do serviço diminui enquanto aumenta o tamanho de um *rally*.

2) Mineração de Sequências: Outra forma de utilizar as informações de *rally* é focar nas sequências de ações tomadas pelos jogadores. Para esse fim, faremos uma mineração de sequência frequentes e, dessa forma, teremos acesso a sequências de ações que são mais comuns para cada jogador. O tamanho dessas subsequências escolhidas foi de 3. Além disso, iremos focar também em ações que levam a resultados desejáveis. Por isso, na maior parte, focaremos em sequências que levam a pontuação do próprio jogador. Faremos também análises em sequências que levam a ***Winners*** e **Erros Forçados**. Como **Erros Não Forçados** são, por definição, causados pelo próprio jogador, sem interferência do adversário, as sequências que encontramos em pontos de **Erros Não Forçados** não trariam informação relevante adicional. As sequências que iremos olhar, também, podem ser tanto de pontos onde os 3 estavam no serviço ou na recepção. Golpes demarcados com ”1” são dos sacadores e ”2” dos que estão recebendo.

As Tabelas XXIII - XXVIII mostram as sequências mais comuns presentes em pontos disputados, no qual os jogadores de interesse foram os vencedores. O tipo de ponto está assinalado em cada respectiva tabela. Para todas as tabelas que se seguirão, as sequências ocorrem enquanto os jogadores estão no serviço. Essas sequências são de maior interesse pois os jogadores têm maior controle durante pontos de serviço e, portanto, esses pontos podem demonstrar melhor suas táticas e estratégias. No caso de pontos de recepção, o jogador está, de certa forma, à mercê das táticas e estratégias dos adversários.

TABLE XXIII
FORCED ERROR SHOT SEQUENCES - FEDERER SERVICE

Shot 1	Shot 2	Shot 3	Support
Wide Serve	Backhand Meio_2	Forehand Cruzado_1	147
Backhand Meio_2	Forehand Cruzado_1	Forehand Cruzado_2	147
Backhand Paralelo_2	Backhand Paralelo_1	Backhand Paralelo_2	141

TABLE XXIV
FORCED ERROR SHOT SEQUENCES - NADAL SERVICE

Shot 1	Shot 2	Shot 3	Support
Forehand Paralelo_1	Backhand Paralelo_2	Forehand Paralelo_1	267
Down The T Serve	Backhand Meio_2	Forehand Paralelo_1	224
Backhand Meio_2	Forehand Paralelo_1	Backhand Meio_2	211

TABLE XXV
FORCED ERROR SHOT SEQUENCES - DJOKOVIC SERVICE

Shot 1	Shot 2	Shot 3	Support
Forehand Cruzado_1	Forehand Cruzado_2	Forehand Paralelo_1	137
Backhand Paralelo_2	Backhand Paralelo_1	Backhand Paralelo_2	124
Forehand Cruzado_2	Forehand Cruzado_1	Forehand Cruzado_2	121

Com essas sequências, já podemos retirar algumas informações. Para as sequências de erro não forçado, podemos ver que, para Nadal e Federer, temos sequências que se seguem diretamente do serviço: serviço aberto para Federer e serviço na linha do T para Nadal. Podemos ver também que no caso do Djokovic, a primeira sequência contém uma troca de direção do sérvio, enquanto as outras duas contém os mesmos golpes em toda a sequência. Isso pode mostrar uma tática de Djokovic: fazer um jogo de espera, apenas passando a bola

TABLE XXVI
WINNER SHOT SEQUENCES - FEDERER SERVICE

Shot 1	Shot 2	Shot 3	Support
Wide Serve	Forehand $Meio_2$	Forehand $Paralelo_1$	278
Wide Serve	Backhand $Meio_2$	Forehand $Cruzado_1$	244
Down The T Serve	Backhand $Meio_2$	Forehand $Cruzado_1$	190

TABLE XXVII
WINNER SHOT SEQUENCES - NADAL SERVICE

Shot 1	Shot 2	Shot 3	Support
Forehand $Paralelo_1$	Backhand $Paralelo_2$	Forehand $Paralelo_1$	296
Down The T Serve	Backhand $Meio_2$	Forehand $Paralelo_1$	254
Wide Serve	Backhand $Meio_2$	Forehand $Cruzado_1$	247

TABLE XXVIII
WINNER SHOT SEQUENCES - DJOKOVIC SERVICE

Shot 1	Shot 2	Shot 3	Support
Forehand $Cruzado_1$	Forehand $Cruzado_2$	Forehand $Paralelo_1$	158
Wide Serve	Backhand $Meio_2$	Forehand $Paralelo_1$	141
Wide Serve	Forehand $Meio_2$	Forehand $Paralelo_1$	138

para o adversário na espera de um erro. E, caso esse erro não venha, temos a troca de direções que ocorre na sequência 1.

Conseguimos, portanto, tirar algumas conclusões sobre o jogo de cada um desses jogadores através dessas sequências. Porém, seria interessante também ver que tipo de sequência diretamente precede suas pontuações. Para isso, iremos considerar apenas os 3 golpes diretamente anteriores a pontuação e iremos minerar as sequências mais frequentes nesse contexto. As tabelas XXIX - XXXIV abaixo são referentes à essas sequências. Novamente, estaremos focando em sequências de **Erro Forçado** e ***Winners***, com os jogadores no serviço:

TABLE XXIX
FORCED ERROR FINAL SHOT SEQUENCES - FEDERER

Shot 1	Shot 2	Shot 3	Support
Backhand $Meio_2$	Forehand $Cruzado_1$	Forehand $Cruzado_2$	82
Backhand $Meio_2$	Forehand $Cruzado_1$	Forehand $Paralelo_2$	65

TABLE XXX
FORCED ERROR FINAL SHOT SEQUENCES - NADAL

Shot 1	Shot 2	Shot 3	Support
Forehand $Cruzado_2$	Backhand $Cruzado_1$	Forehand $Paralelo_2$	61
Backhand $Meio_2$	Forehand $Cruzado_1$	Forehand $Cruzado_2$	53
Backhand $Meio_2$	Forehand $Cruzado_1$	Forehand $Paralelo_2$	51

Para o caso das sequências de Erro Forçado, devemos olhar para o ”Shot 2”, que é a ação de fato dos jogadores que estamos interessados. Dessa forma, vemos que o mesmo

TABLE XXXI
FORCED ERROR FINAL SHOT SEQUENCES - DJOKOVIC

Shot 1	Shot 2	Shot 3	Support
Forehand $Cruzado_2$	Forehand $Cruzado_1$	Forehand $Paralelo_2$	53
BH Slice $Meio_2$	Forehand $Cruzado_1$	Forehand $Cruzado_2$	40
Backhand $Paralelo_2$	Backhand $Cruzado_1$	Forehand $Cruzado_2$	40

TABLE XXXII
WINNER FINAL SHOT SEQUENCES - FEDERER

Shot 1	Shot 2	Shot 3	Support
Wide Serve	Forehand $Meio_2$	Forehand $Paralelo_1$	170
Wide Serve	Backhand $Meio_2$	Forehand $Cruzado_1$	153
Wide Serve	Backhand $Meio_2$	Forehand $Paralelo_1$	107

TABLE XXXIII
WINNER FINAL SHOT SEQUENCES - NADAL

Shot 1	Shot 2	Shot 3	Support
Wide Serve	Backhand $Meio_2$	Forehand $Cruzado_1$	124
Forehand $Paralelo_1$	Backhand $Paralelo_2$	Forehand $Cruzado_1$	115
Wide Serve	Backhand $Paralelo_2$	Forehand $Cruzado_1$	94

TABLE XXXIV
WINNER FINAL SHOT SEQUENCES - DJOKOVIC

Shot 1	Shot 2	Shot 3	Support
Down The T Serve	Forehand $Meio_2$	Forehand $Cruzado_1$	62
Wide Serve	Backhand $Meio_2$	Forehand $Paralelo_1$	61
Down The T Serve	BH Slice $Meio_2$	Forehand $Cruzado_1$	60

golpe foi utilizado em todas as sequências mais comuns para levar ao erro forçado do adversário no golpe seguinte. Um golpe cruzado seguido de um erro na tentativa de resposta, o que demonstra o poder que essa troca de direção tem para desestabilizar o adversário. Ainda podemos notar a diferença no fato de que, para Nadal, o golpe cruzado mais comum é um *Backhand*. Como Nadal é canhoto e joga a maioria dos jogos contra destros, essa mudança acontece.

No caso dos *Winners*, temos uma outra informação bem clara: as sequências de *winners* acontecem frequentemente poucos golpes após o serviço. Para Nadal e Federer, o serviço mais utilizado é o aberto e, no caso de Djokovic, o na linha do T. O que isso mostra é a forte influência do serviço nos primeiros golpes. O controle dos jogadores é maior durante esse momento e, portanto, é nesses estágios iniciais do ponto que eles buscam o *winner*. Isso entra em contraste com as sequências de **Erro Forçado** que não parecem possuir essa influência direta dos serviços.

Pelas tabelas, fica claro que existem algumas estratégias que são utilizadas pelos 3, o que mostra que elas são eficazes. Porém, podem existir também sutilezas e diferenças nessas sequências que nos informam um pouco mais sobre o estilo

de jogo de cada um dos 3.

F. Pontos Chave

Nesta seção, estaremos olhando as estatísticas referentes aos pontos chave do jogo. São pontos com significado e importância especial durante a partida e a capacidade de se sobressair nesses momentos pode ser crucial para a vitória ou derrota. Antes, algumas definições das informações encontradas nas tabelas

- **BP** - **Breaking Points** ou ”Pontos de Quebra” são disputados quando um jogador tem a oportunidade de vencer um *game* de serviço do adversário. Pelas seções passadas, sabemos a relevância do serviço para o desempenho de um jogador. Portanto, a oportunidade de ”quebrar” um serviço é uma grande chance.
- **GP** - **Game Points** são os pontos disputados quando um jogador tem a chance de vencer o seu *game* de serviço. Pelas mesmas razões explicitadas anteriormente, fazer valer o próprio serviço é extremamente importante para a vitória.
- **Deuce** - Ao final de *games*, jogadores podem estar empatados em pontos **40-40** (ou, de uma forma mais ”simples”, 3-3). Quando isso ocorre, um jogador deve ganhar dois pontos em sequência para ganhar o *game*. Os pontos disputados nessa situação são chamados **Deuce Points**

Iremos observar pontos chaves tanto do lado do serviço quanto da recepção. Dessa forma, podemos entender esses pontos da seguinte forma: os pontos da primeira subseção são aqueles onde o jogador tem a iniciativa, enquanto na segunda, ele está na defensiva e sob a ameaça de perder um *game*.

1) Iniciativa: As Tabelas XXXV - XXXVII mostram os dados dos pontos chaves de onde os jogadores têm a iniciativa. Começando pelos pontos de quebra, podemos ver que as taxas de 65% para Nadal e Federer e 64% para Djokovic são notáveis se comparadas às que vimos na **seção B**. Na condição de recepção, que é a que eles se encontram ao jogarem pontos de quebra, todos os 3 tem aproximadamente 40% de aproveitamento. No entanto, nessa situação extraordinária, seu aproveitamento sobe aproximadamente 25%, mostrando a força e qualidade desses jogadores. No caso de *game points*, seus aproveitamento são ligeiramente melhores que os usuais e o mesmo pode ser dito dos *deuce points*. Isso mostra a capacidade destes 3 jogadores de aproveitarem as oportunidades à sua disposição e elevarem o seu nível em momentos chave.

TABLE XXXV
PONTOS CHAVE - FEDERER

	Pontos	Pontos Vencidos	Aces	Winner	Forced Error	Unforced Error	% Primeiro Serviço
BP	2357	0.654	-	0.232	0.175	0.265	-
GP	8373	0.7	0.161	0.245	0.121	0.183	0.632
Deuce	3975	0.688	0.155	0.244	0.147	0.216	0.644
STotal	14705	0.689	0.152	0.243	0.136	0.205	0.63

TABLE XXXVI
PONTOS CHAVE - NADAL

	Pontos	Pontos Vencidos	Aces	Winner	Forced Error	Unforced Error	% Primeiro Serviço
BP	2064	0.648	-	0.253	0.194	0.229	-
GP	5463	0.685	0.094	0.244	0.143	0.165	0.674
Deuce	2994	0.64	0.045	0.204	0.168	0.221	0.72
STotal	10521	0.665	0.073	0.235	0.16	0.192	0.692

TABLE XXXVII
PONTOS CHAVE - DJOKOVIC

	Pontos	Pontos Vencidos	Aces	Winner	Forced Error	Unforced Error	% Primeiro Serviço
BP	2069	0.636	-	0.22	0.198	0.29	-
GP	5723	0.666	0.114	0.212	0.152	0.223	0.658
Deuce	3212	0.664	0.089	0.205	0.188	0.252	0.666
STotal	11004	0.66	0.098	0.211	0.171	0.243	0.656

TABLE XXXVIII
PONTOS CHAVE ENFRENTADOS - FEDERER

	Pontos	Pontos Vencidos	Winner	Forced Error	Unforced Error
BPO	4015	0.4	0.263	0.209	0.417
GPF	8084	0.386	0.271	0.24	0.44
DeuceR	5416	0.391	0.28	0.21	0.442
RTotal	17515	0.39	0.272	0.223	0.435

TABLE XXXIX
PONTOS CHAVE ENFRENTADOS - NADAL

	Pontos	Pontos Vencidos	Winner	Forced Error	Unforced Error
BPO	2945	0.433	0.258	0.172	0.262
GPF	5108	0.377	0.248	0.225	0.347
DeuceR	3649	0.4	0.246	0.196	0.289
RTotal	11702	0.398	0.25	0.201	0.305

TABLE XL
PONTOS CHAVE ENFRENTADOS - DJOKOVIC

	Pontos	Pontos Vencidos	Winner	Forced Error	Unforced Error
BPO	2899	0.432	0.165	0.213	0.298
GPF	5241	0.391	0.274	0.28	0.39
DeuceR	3789	0.395	0.207	0.253	0.351
RTotal	11929	0.402	0.224	0.254	0.354

2) Defensiva: No caso das situações chave onde eles estavam na defensiva, o panorama é bem diferente. Essas informações estão nas Tabelas XXXVIII - XL. Quando estavam sofrendo a possibilidade de quebra, eles venceram aproximadamente 40% dos pontos. Na seção B deste relatório, constatamos que geralmente essa taxa é de 60% no serviço e, portanto, existe uma queda significativa. Porém, nos demais pontos, as estatísticas parecem ser condizentes com as outras estatísticas de recepção que apresentamos. Dessa forma, existe uma outra interpretação para entender essa queda nos pontos de serviço: Nesse tipo de cenário, onde a chance da vitória adversária é grande, e o esforço necessário para defender é considerável, os jogadores podem optar por se preservar e não disputar esses pontos com tanta energia. Portanto, essa escolha, caso ela seja feita, pode ser vista como uma tática desses jogadores. Seria melhor perder esses pontos, e preservar energia, do que se esforçar para um resultado que é incerto.

V. Conclusão

Através da análise estatística e a utilização de técnicas de mineração de sequências, somos capazes de encontrar informações relevantes sobre o estilo de jogo de jogadores de tênis.

Através da análise, conseguimos enxergar, estatisticamente, fatores como a importância do serviço, além dos diferentes tipos de serviço e de seus casos de uso mais comuns, como foi o caso do serviço no corpo para segundo serviços ou o serviço na linha do T em tentativas de ace. Observamos os golpes mais comumente utilizados e seus impactos no jogo, desde a preferência de finalização de pontos por *forehand* e a utilização de *slices* para controle e construção do ponto. Ao focarmos nos aspectos dos rallys, foi possível descobrir as diferenças existentes entre pontos de tamanhos diferentes. Foi possível perceber como a maioria dos pontos acontece em rallys curtos e como, à medida que o rally cresce, o impacto do serviço diminui. Além disso, ao olharmos para as sequências mais comumente empregadas pelos 3 jogadores, descobrimos a forma como eles se assemelham e se diferenciam durante um ponto. Por último, observamos os pontos chaves durante o jogo. Dessa forma, conseguimos realizar com sucesso a exploração desses conjunto de dados inicial que era proposta para essa primeira parte do projeto, e abrimos diversos caminhos que parecem interessantes para serem explorados com maior profundidade na sequência.

References

[1] Rory Bunker, Keisuke Fujii, Hiroyuki Hanada, and Ichiro Takeuchi. Supervised sequential pattern mining of event sequences in sport to identify important patterns of play: An application to rugby union. *PLOS ONE*, 16(9):1–19, 09 2021.

[2] Mark Carey. How data departments have evolved and spread across english football clubs. *New York Times - The Athletic*, September 3 2024.

[3] Pierre Duluard, Xinqing Li, Marc Plantevit, Céline Robardet, and Romain Vuillemot. Discovering and visualizing tactics in a table tennis game based on subgroup discovery. In Ulf Brefeld, Jesse Davis, Jan Van Haaren, and Albrecht Zimmermann, editors, *Machine Learning and Data Mining for Sports Analytics*, pages 101–112, Cham, 2023. Springer Nature Switzerland.

[4] Claire Justin, Tom Griggs, and Richard Topping. The business of football: the big data arms race. *Financial Times*, Semptember 27 2024.

[5] M. Lewis. *Moneyball: The Art Of Winning An Unfair Game*. Business book summary. WW Norton, 2003.

[6] Robson Parmezan Bonidia, Jacques Duilio Brancher, and Rosangela Marques Busto. Data mining in sports: A systematic review. *IEEE Latin America Transactions*, 16(1):232–239, 2018.